

Caso de Estudio 4: Banco o Fintech

Caso de Uso: Detección de fraude en tiempo real.

Descripción Ampliada: Las entidades financieras enfrentan el reto constante de proteger las transacciones de sus clientes. Un sistema de detección de fraude tradicional es lento y puede fallar con patrones de ataque modernos. El Big Data lo resuelve así:

- **Análisis en Tiempo Real:** Cada transacción de tarjeta de crédito, transferencia bancaria o movimiento en una cuenta genera datos que se analizan en milisegundos. El sistema no solo ve la transacción actual, sino que la compara con el historial de compras del cliente (ubicación, hora, monto, tipo de comercio) y con patrones de fraude conocidos a nivel global.
- **Modelos Predictivos:** Un modelo de machine learning se entrena con millones de transacciones fraudulentas y legítimas para identificar anomalías. Si una compra no encaja con el comportamiento habitual del cliente o con los patrones de la mayoría, el sistema puede bloquear instantáneamente o enviar una alerta.

CONSIGNAS

1. Las 5 V's del Big Data:

■ **Volumen:** ¿Qué tipo de datos masivos se generan o manejan? ¿De qué escala hablamos (terabytes, petabytes)?

Un banco o una fintech genera y procesa enormes cantidades de datos provenientes de:

- Compras con tarjetas de crédito y débito.
- Transferencias bancarias.
- Pagos digitales y movimientos de cuentas.
- Inicios de sesión y dispositivos utilizados.
- Ubicación geográfica de las operaciones.
- Historial de transacciones de cada cliente.
- Intentos de acceso y operaciones rechazadas.
- Registros de fraudes anteriores.

Una entidad grande puede procesar millones de transacciones por día. Al conservar varios años de historial, el volumen puede alcanzar terabytes o incluso petabytes.

■ **Velocidad:** ¿Los datos se procesan en tiempo real o por lotes? ¿Por qué esa velocidad es crucial para el éxito de la empresa?

Los datos deben procesarse principalmente en tiempo real o en milisegundos.

Esta velocidad es crucial porque el sistema debe evaluar la transacción antes de autorizarla. Si el análisis fuera lento, el dinero podría transferirse o la compra fraudulenta podría concretarse antes de detectar el problema.

Por ejemplo, si un cliente realiza una compra de gran valor desde una ubicación inusual, el sistema debe decidir inmediatamente si:

- Autoriza la operación.
- Solicita una verificación adicional.
- Envía una alerta.
- Bloquea temporalmente la transacción.

■ **Variedad:** ¿Qué tipos de datos se utilizan (estructurados, no estructurados, semi-estructurados)?

Ejemplos de tipos de dato:

- **Estructurados** : Monto, fecha, número de cuenta, saldo, tipo de comercio y código de transacción
- **Semiestructurados**: Registros del sistema, archivos JSON, datos de aplicaciones y eventos digitales
- **No estructurados**: Correos, reclamos, grabaciones de llamadas, imágenes de documentos y comentarios de clientes

■ **Veracidad:** ¿Qué desafíos de calidad y confiabilidad de datos podrían enfrentar?

Los principales desafíos de calidad y confiabilidad son:

- Datos incompletos o desactualizados.
- Transacciones duplicadas.
- Errores en la ubicación del dispositivo.
- Clientes que cambian repentinamente sus hábitos.
- Información incorrecta proporcionada durante el registro.
- Fraudes nuevos que todavía no están identificados.
- Operaciones legítimas que parecen sospechosas.

Uno de los mayores problemas son los falsos positivos: transacciones legítimas bloqueadas por error. También existen falsos negativos, cuando una operación fraudulenta no es detectada.

Por eso, los datos y modelos deben revisarse, limpiarse y actualizarse constantemente.

■ **Valor:** ¿Cuál es el beneficio de negocio (ganancias, eficiencia, satisfacción del cliente) que se obtiene del Big Data en este caso?

Big Data aporta valor porque permite:

- Reducir las pérdidas económicas ocasionadas por fraudes.
- Detectar operaciones sospechosas antes de que se concreten.
- Automatizar el análisis de millones de transacciones.
- Disminuir el trabajo manual de los analistas.
- Proteger la información y el dinero de los clientes.
- Aumentar la confianza y satisfacción del cliente.
- Cumplir con regulaciones financieras.
- Adaptarse rápidamente a nuevas modalidades de fraude.

El desafío es mantener un equilibrio entre seguridad y experiencia del cliente, evitando bloquear innecesariamente operaciones legítimas.

2. Almacenamiento:

■ ¿Dónde se almacenarán estos datos? ¿Creen que sería un sistema de archivos distribuido como HDFS, un Data Lake o una base de datos más Tradicional?

Lo mejor sería usar una arquitectura combinada:

- Una base de datos transaccional para registrar operaciones actuales y consultar saldos rápidamente.
- Un Data Lake para almacenar grandes cantidades de datos históricos, registros, eventos y datos en diferentes formatos.
- Almacenamiento en la nube para ampliar la capacidad según el volumen.
- Un Data Warehouse para elaborar reportes, indicadores y análisis de negocio.

■ ¿Qué desafíos de escalabilidad y costo enfrentarían al almacenar estos datos?

- Crecimiento constante del volumen de información.
- Costo del almacenamiento histórico.
- Necesidad de infraestructura disponible las 24 horas.
- Copias de seguridad y recuperación ante fallas.
- Replicación de datos en diferentes servidores.
- Costo de procesamiento de grandes volúmenes.
- Necesidad de conservar algunos datos durante varios años.
- Eliminación segura de información que ya no debe conservarse.

Para controlar los costos, la entidad puede clasificar los datos según prioridad. Los datos recientes y utilizados frecuentemente se mantienen en sistemas rápidos, mientras que los datos antiguos se trasladan a almacenamiento más económico.


3. Procesamiento y Análisis:

■ ¿Qué tipo de procesamiento se necesita (por lotes o en streaming)?

El sistema necesita combinar dos modalidades:

Procesamiento en streaming: analiza cada transacción en el momento en que ocurre. Se utiliza para detectar el fraude y tomar una decisión inmediata.

Procesamiento por lotes: analiza grandes conjuntos de datos históricos en determinados momentos. Se utiliza para entrenar modelos, descubrir nuevos patrones y generar informes.



■ ¿Qué herramientas de análisis serían las más adecuadas (ej. SQL, Python, machine learning)?

- **SQL:** consultas sobre transacciones, clientes, comercios y reportes.
- **Machine learning:** identificación de anomalías y predicción del riesgo, como fraudes, clientes morosos, etc.
- **Apache Spark:** procesamiento rápido de grandes volúmenes y flujos de datos.
- **Herramientas de BI:** creación de tableros con alertas, cantidad de fraudes, pérdidas evitadas e indicadores para reportes a gerente y clientes.

Analizar variables como:

- Monto de la operación – Hora y ubicación – Frecuencia de compras – Comercio utilizado – Dispositivo y dirección IP – Distancia respecto de la operación anterior – Cantidad de intentos fallidos – Comportamiento habitual del cliente

4. Gobernanza y Seguridad:

■ ¿Qué datos sensibles o personales podrían estar manejando? (ej. Datos personales de clientes, historial de navegación)?

Datos personales	• Nombre, DNI y domicilio. • Número de cuenta o tarjeta. • Historial de compras y transferencias. • Saldo e ingresos • Contraseñas y credenciales de acceso.
Historial de navegación	• Dirección IP y dispositivo. • Datos biométricos. • Información laboral y financiera. • Contactos y destinatarios frecuentes • Ubicación geográfica.

■ ¿Qué desafíos de seguridad y privacidad tendrían que considerar para proteger la información?

Los principales desafíos son:

- Evitar accesos no autorizados.
- Prevenir filtraciones y robos de información.
- Proteger los datos durante su almacenamiento y transmisión.
- Cumplir con las normas de protección de datos.
- Limitar el acceso según el rol de cada empleado.
- Mantener registros de quién consulta o modifica la información.
- Evitar el uso de los datos para fines no autorizados.
- Proteger los modelos frente a manipulaciones o ataques.
- Informar adecuadamente al cliente sobre el uso de sus datos.

Las medidas recomendadas incluyen:

- Cifrado de datos.
- Autenticación multifactor.
- Control de acceso por roles.
- Tokenización de números de tarjetas.
- Anonimización de datos para entrenar modelos.
- Auditorías y monitoreo continuo.
- Copias de seguridad.

- Planes de respuesta ante incidentes.
- Revisión periódica de los modelos para evitar errores o sesgos.