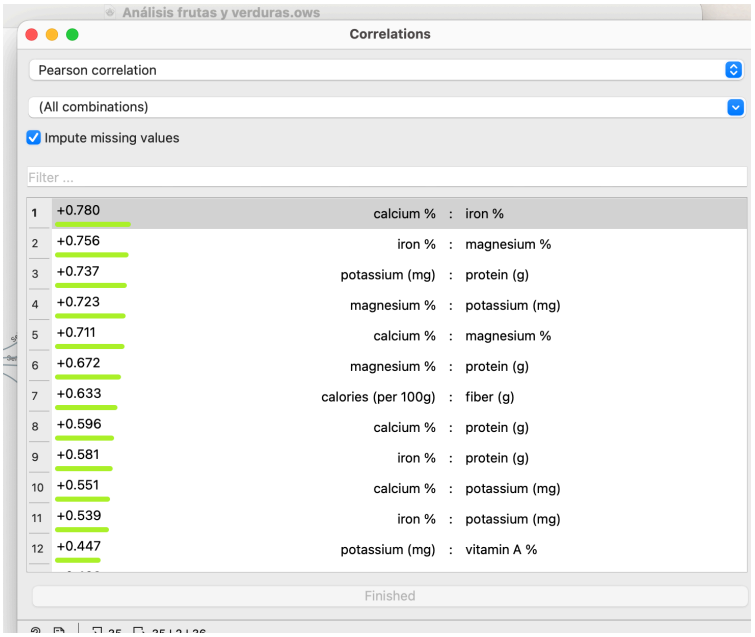
Entrega Big Data - clase 8/10

Grupo 4: CyberG

EDA

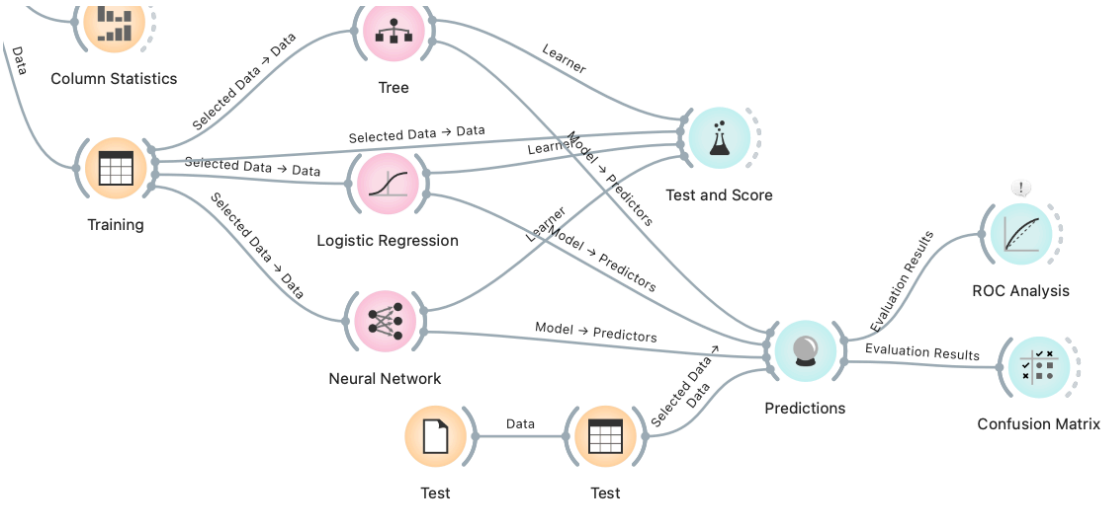
Durante el análisis exploratorio utilizamos la herramienta Correlations para estudiar las relaciones entre los nutrientes. La correlación de Pearson más alta fue entre calcio y hierro, con un valor de 0,780. También encontramos correlaciones positivas entre hierro y magnesio, de 0,756, y entre potasio y proteína, de 0,737.

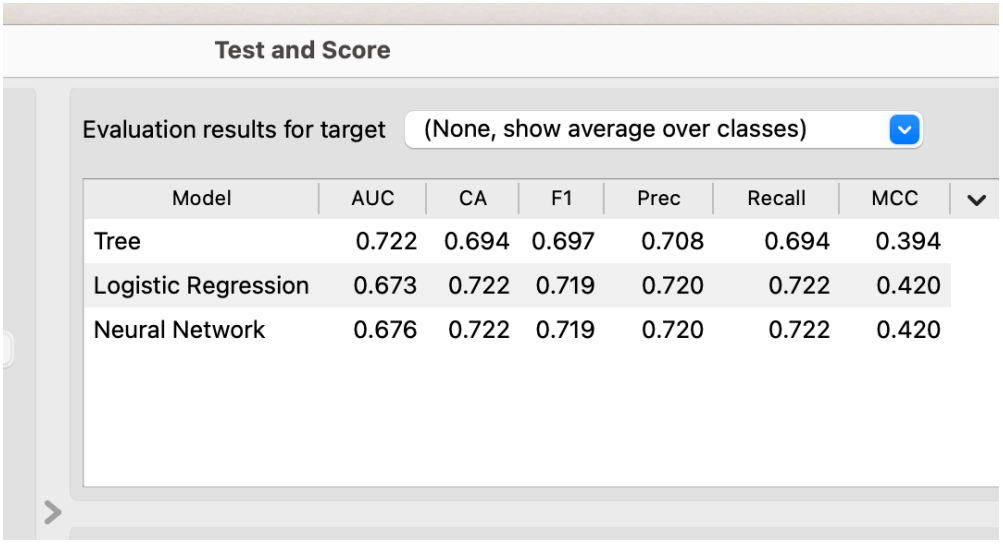
Observamos que los alimentos con mayor contenido de calcio suelen tener también mayor contenido de hierro. Esto muestra una relación entre ambos nutrientes en los datos analizados, pero no significa que uno cause el aumento del otro.



Training

Utilizamos Tree, Logistic Regression y Neural Network para clasificar los alimentos según sus nutrientes. En Test and Score, Logistic Regression y Neural Network alcanzaron un 72,2 % de aciertos y Tree un 69,4 %. Sin embargo, Tree obtuvo el mayor AUC (0,722).





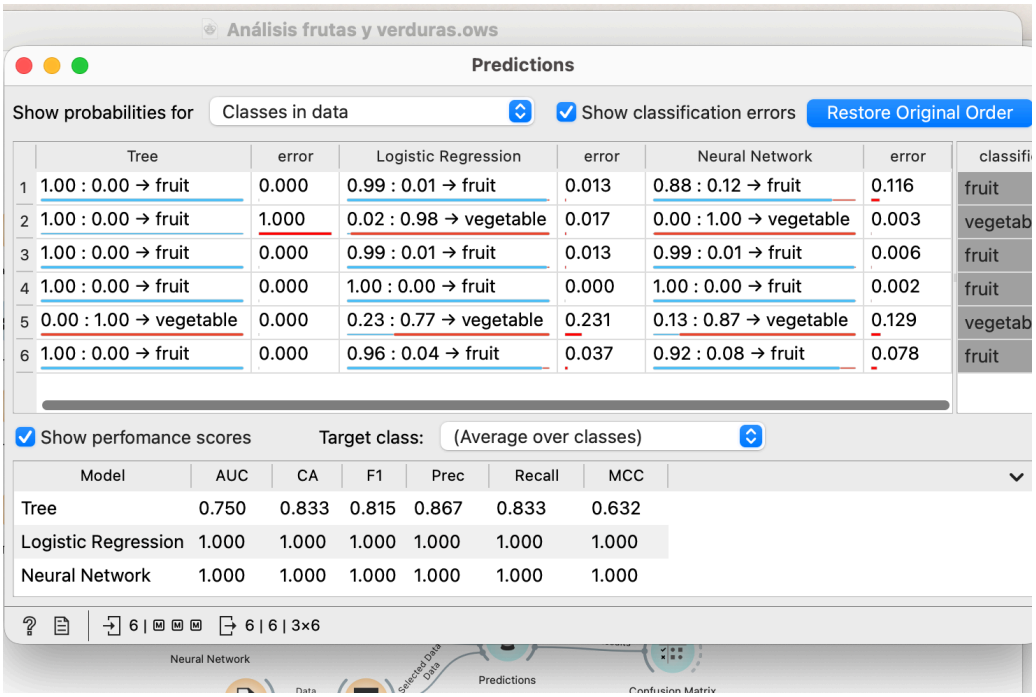
Test and Score

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.722	0.694	0.697	0.708	0.694	0.394
Logistic Regression	0.673	0.722	0.719	0.720	0.722	0.420
Neural Network	0.676	0.722	0.719	0.720	0.722	0.420

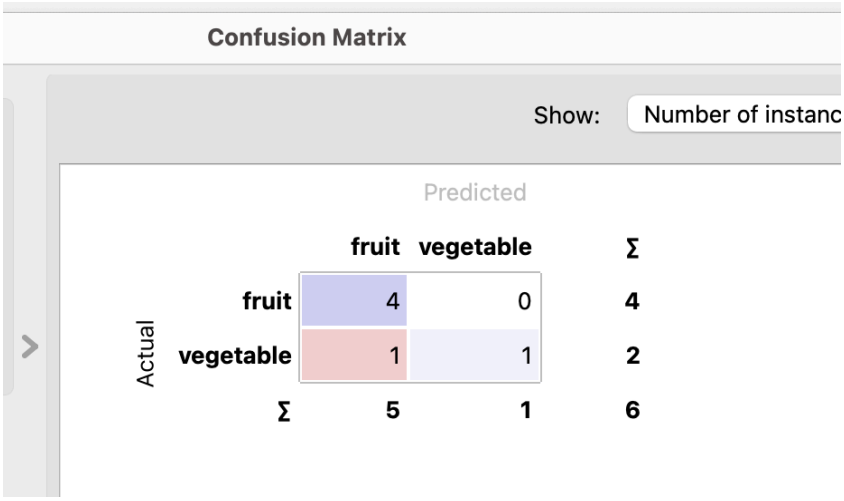
Etapa de testeo

Con Predictions aplicamos los modelos entrenados a los seis alimentos del archivo de prueba. Comparamos sus predicciones con las categorías reales para evaluar los aciertos y errores, que analizamos mediante la matriz de confusión y las curvas ROC.



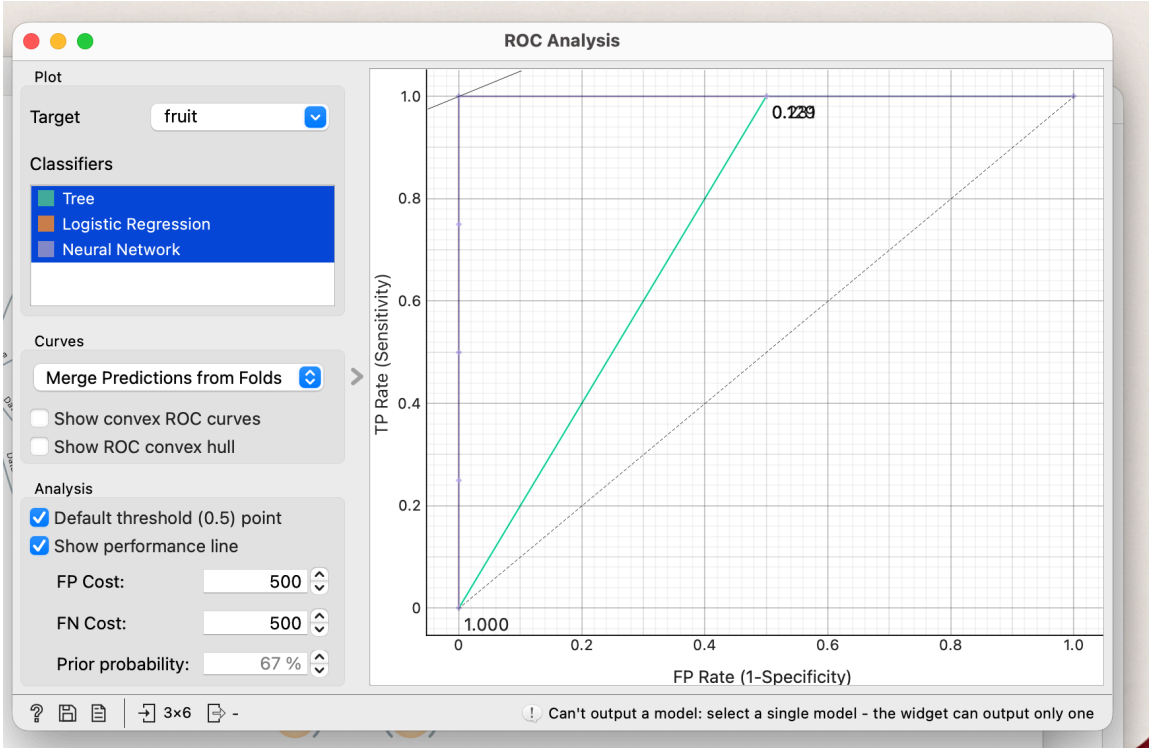
Matriz de confusión

El modelo clasificó correctamente las cuatro frutas y uno de los dos vegetales. El otro vegetal fue clasificado como fruta, obteniendo cinco aciertos de seis (83,33 %). El único error consistió en predecir la categoría fruit para un alimento que su categoría real era vegetable.



Análisis ROC

Logistic Regression y Neural Network presentan curvas superpuestas con una separación perfecta entre las clases en esta prueba. Tree muestra un desempeño inferior. Las curvas más cercanas a la esquina superior izquierda indican una mejor discriminación.



Conclusión

Los modelos obtuvieron mejores resultados en el archivo de prueba que en Test and Score. Sin embargo, la prueba incluye solo seis registros y tres son idénticos a ejemplos de entrenamiento, por lo que estos resultados no garantizan el mismo desempeño con alimentos nuevos.