Entrega Feature Engineering - Big Data
Grupo: CyberG
Alumnas: Avila Delfina, Colimodio Clara, Gaviña Bernardina, Gonzalez Solana y Olivares Delfina

Resultados y conclusiones

Comparación de los modelos

En el modelo base, Logistic Regression obtuvo el AUC más alto, mientras que Random Forest presentó los mejores resultados de Accuracy y F1. Estos valores se utilizaron como referencia para evaluar el efecto de las variables nuevas.

Después de aplicar Feature Engineering, Random Forest fue el único algoritmo que mejoró en las principales métricas. Su AUC pasó de 0,895 a 0,898, su Accuracy de 0,853 a 0,855 y su F1 de 0,669 a 0,673. Neural Network y Logistic Regression disminuyeron ligeramente su desempeño.

Para completar la comparación solicitada:

- Logistic Regression: AUC 0,902 a 0,898; Accuracy 0,851 a 0,848; F1 0,654 a 0,643.
- Neural Network: AUC 0,885 a 0,882; Accuracy 0,839 a 0,838; F1 0,651 a 0,642.
- Random Forest: AUC 0,895 a 0,898; Accuracy 0,853 a 0,855; F1 0,669 a 0,673.

Matriz de confusión

La matriz de confusión de Neural Network muestra que el modelo clasificó correctamente la mayoría de los casos. Sin embargo, también presentó 4.590 falsos negativos, es decir, personas con ingresos superiores a 50K que fueron clasificadas como ≤50K. Para una empresa, estos errores representarían clientes potenciales que no recibirían una oferta premium.

Curva ROC

Las curvas ROC de los tres modelos se encuentran por encima de la diagonal, lo que indica que todos clasifican mejor que un modelo aleatorio. Random Forest y Logistic Regression obtuvieron los mayores valores de AUC después del Feature Engineering. No obstante, Random Forest mostró el mejor equilibrio general porque también alcanzó los mejores valores de Accuracy y F1.

Preguntas de reflexión

Impacto en los modelos

Random Forest fue el algoritmo que más se benefició de las variables nuevas, ya que fue el único que mejoró en AUC, Accuracy y F1. Esto puede suceder porque los árboles aprovechan bien

variables con umbrales e interacciones, como el indicador de trabajar más de 45 horas semanales.

Interpretabilidad y negocio

La variable net_capital_gain es útil porque resume en un solo valor la diferencia entre ganancias y pérdidas de capital. Para un equipo de marketing o riesgo resulta más fácil interpretar el balance financiero neto de una persona que analizar ambas variables por separado.

Ética y sesgo

Usar is_overwork para aprobar créditos podría perjudicar a personas que trabajan menos horas por responsabilidades familiares, problemas de salud o empleos de tiempo parcial. También podría premiar jornadas laborales poco saludables. Por eso, no debería utilizarse como único criterio de decisión.

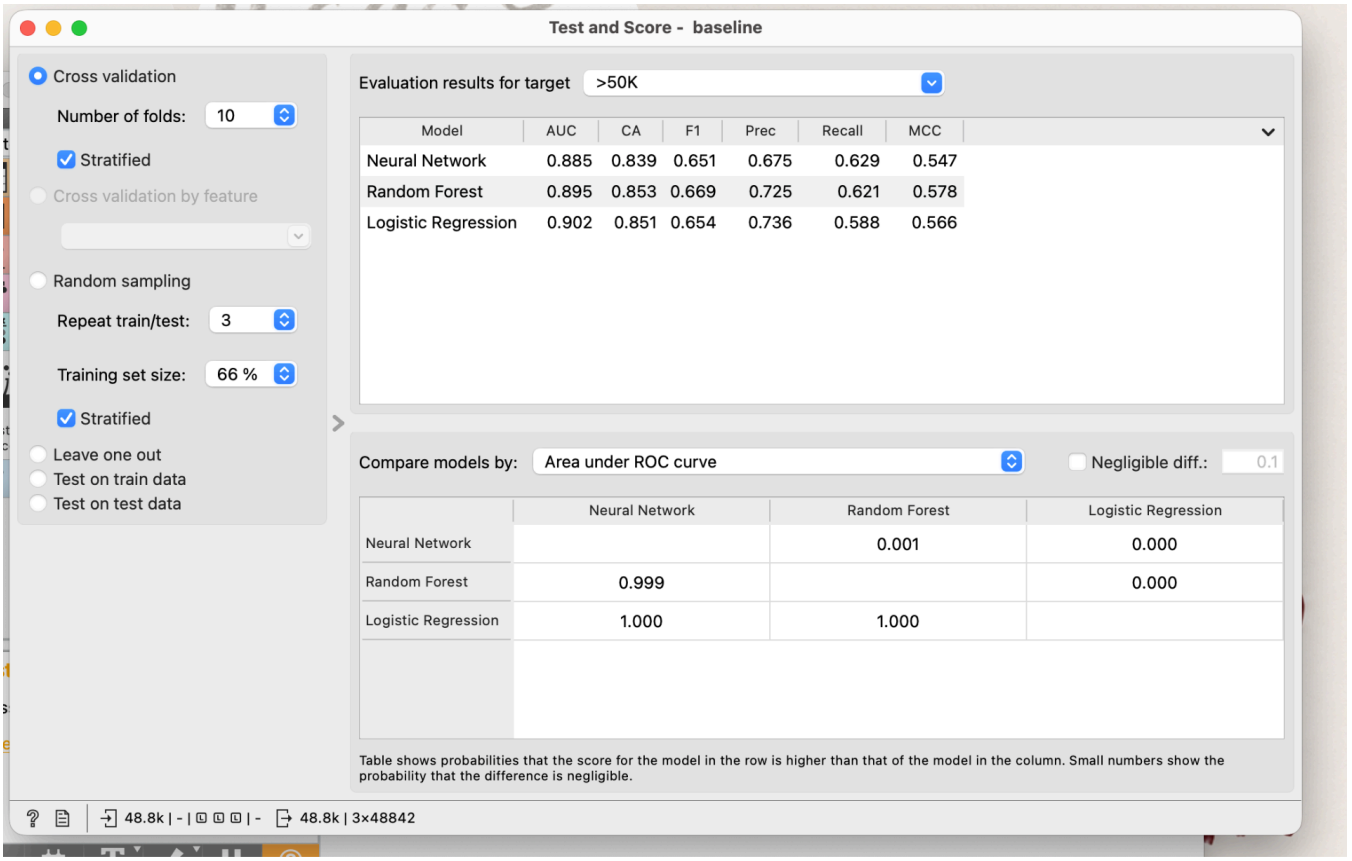
Propuesta de una variable adicional

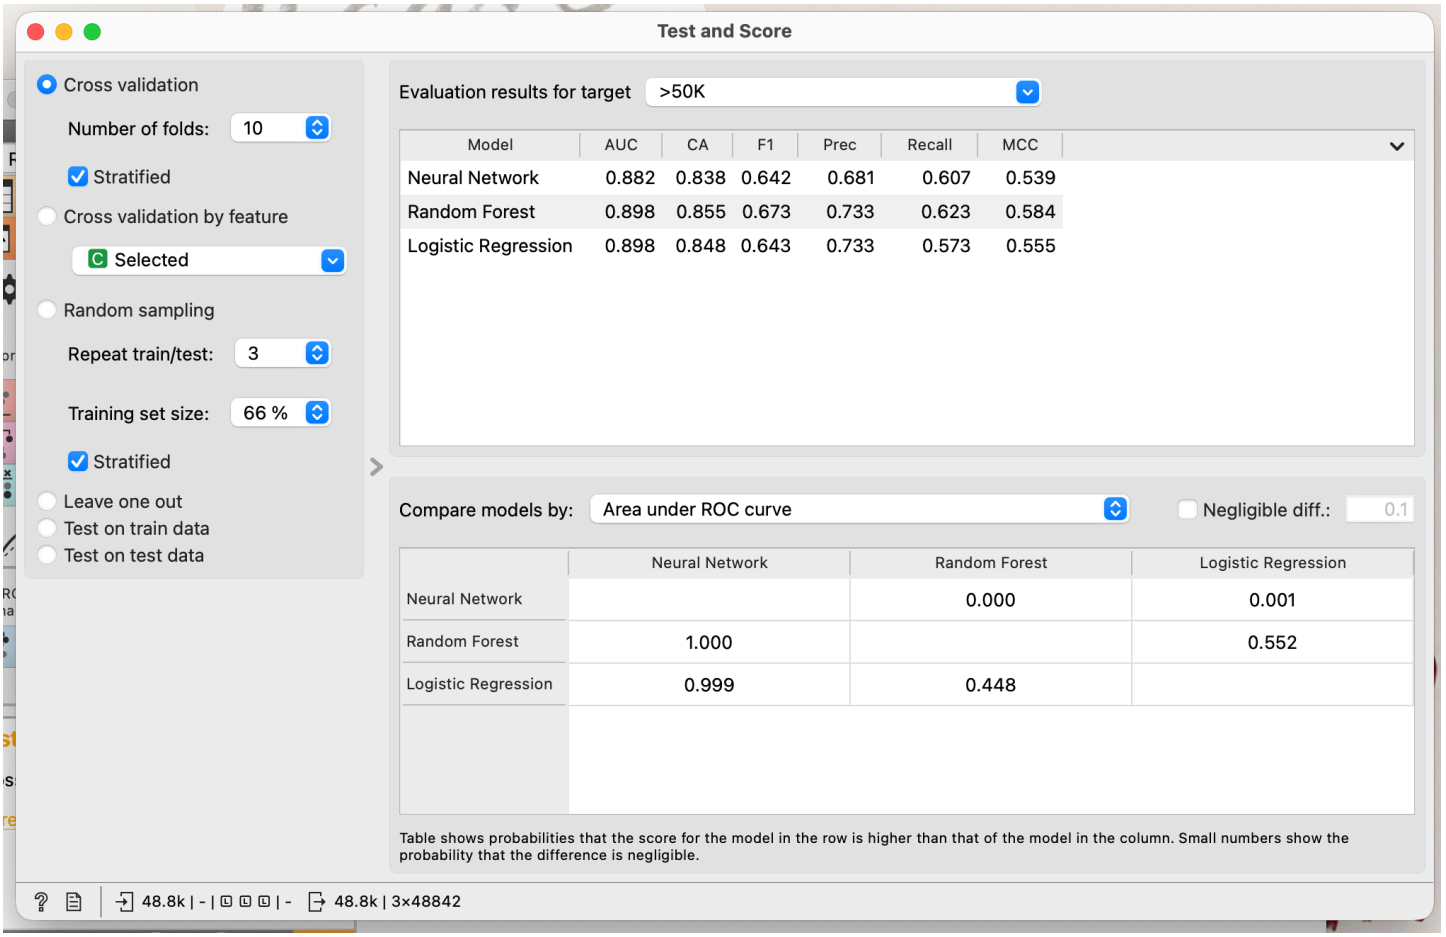
Se propone crear education_work_intensity mediante la fórmula education_num multiplicado por hours_per_week. Esta variable combinaría el nivel educativo con la dedicación laboral, dos aspectos que podrían relacionarse con empleos especializados y mayores ingresos.

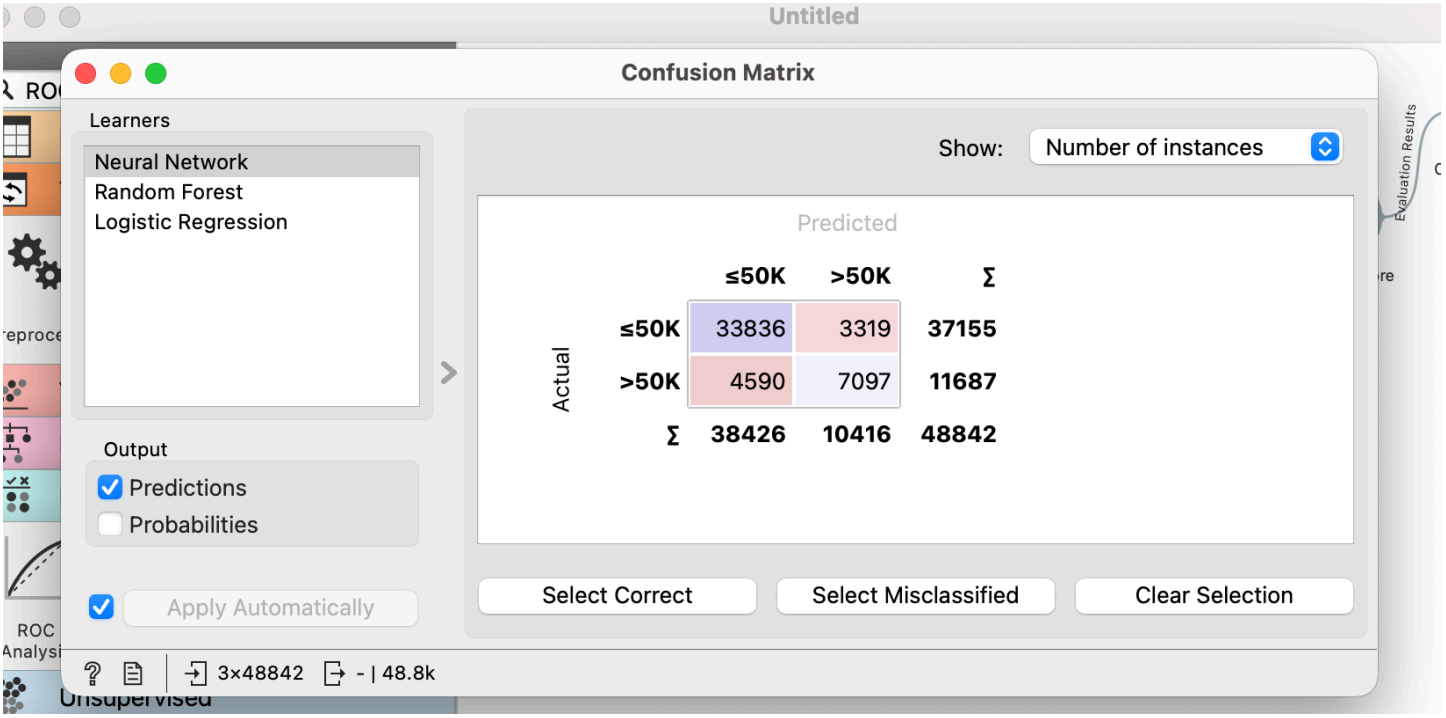
Conclusión

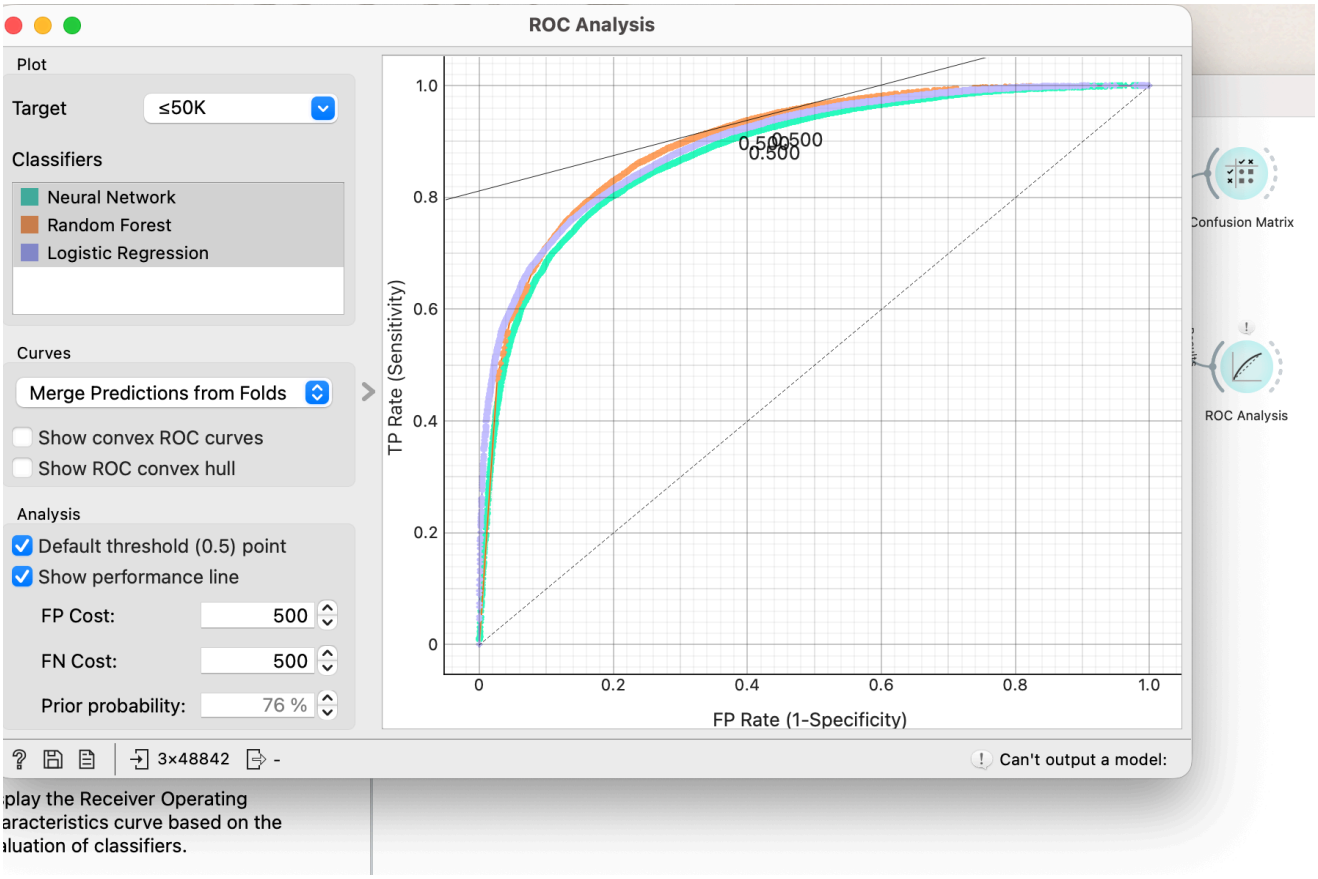
El Feature Engineering produjo una mejora pequeña y solamente en Random Forest. Esto demuestra que crear variables nuevas no garantiza mejores resultados para todos los algoritmos. En este ejercicio, Random Forest fue el modelo con mejor desempeño final, mientras que las variables creadas también aportaron una interpretación más directa desde el punto de vista del negocio.

Evidencia de Orange:






Untitled
Confusion Matrix
Learners
Neural Network
Random Forest
Logistic Regression
Show:
Number of instances
Predicted
≤50K
>50K
Σ
Actual
≤50K
33836
3319
37155
>50K
4590
7097
11687
Σ
38426
10416
48842
Output
Predictions
Probabilities
Apply Automatically
Select Correct
Select Misclassified
Clear Selection
3×48842
- | 48.8k


ROC Analysis
Plot
Target
≤50K
Classifiers
Neural Network
Random Forest
Logistic Regression
Curves
Merge Predictions from Folds
Show convex ROC curves
Show ROC convex hull
Analysis
Default threshold (0.5) point
Show performance line
FP Cost:
500
FN Cost:
500
Prior probability:
76 %
TP Rate (Sensitivity)
FP Rate (1-Specificity)
0.500
3×48842
Can't output a model:
Confusion Matrix
ROC Analysis