

Big Data - Analisis Exploratorio de Datos

Utilizando la herramienta Orange Data Mining, importe el archivo de datos hogares.csv y Elabore un informe con las respuestas a las preguntas indicadas en esta guía. Hogares.csv contiene datos ficticios de 100 hogares encuestados.

Condiciones de entrega

- Entrega Grupal: Deben entregarlo por Github con el nombre del grupo
- Plazo máximo: hasta la siguiente clase.

Diccionario de Datos

HogarID: Identificador único del hogar, entero que va de 1 a 100.

IngresoMensual: Ingresos totales del hogar por mes, en pesos argentinos (ARS). Representa la suma de todos los ingresos de los miembros del hogar.

GastoMensual: Gastos totales del hogar por mes, en pesos argentinos (ARS). Incluye gastos fijos (como alquiler o hipoteca, servicios, etc.) y gastos variables (como alimentación, transporte, ocio).

NumPersonas: Número de personas que conforman el hogar. Valor entero que indica la cantidad de individuos viviendo en el hogar.

TipoVivienda: Tipo de estructura habitacional donde reside el hogar. Puede ser "Casa" o "Departamento", reflejando las diferentes modalidades de vivienda.

ZonaVivienda: Zona geográfica donde se ubica el hogar. Las categorías incluyen "Urbana", "Suburbana" y "Rural", indicando el contexto geográfico y posiblemente socioeconómico de la vivienda.

EdadPromedioHogar: Edad promedio de los miembros del hogar, en años. Esta variable es un promedio de las edades de todos los individuos que conforman el hogar.

Guía de Preguntas

1. Análisis de Tendencia Central y Dispersión (Feature Statistics y Distributions):
Calcule las medidas de tendencia central (media, mediana) y dispersión (varianza, desviación estándar) para las variables IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Los valores encontrados son consistentes con lo que esperarías en un contexto económico real?

El análisis se realizó combinando Column Statistics, Distributions y Violin Plot, con el objetivo de no limitar la interpretación únicamente a los promedios. El ingreso mensual presenta una media de \$91.719,9 y una mediana de \$91.055,7, mientras que el gasto mensual posee una media de \$62.151,3 y una mediana de \$62.352,3. La cercanía entre media y mediana indica que ambas variables presentan centros de distribución relativamente equilibrados.

Las desviaciones estándar aproximadas son \$32.559,8 para el ingreso y \$24.979,4 para el gasto, indicando una considerable heterogeneidad económica entre los hogares. Además, el ingreso promedio es superior al gasto promedio.

Esta coherencia económica se refuerza mediante el análisis de correlaciones, donde IngresoMensual y GastoMensual presentan una correlación positiva muy fuerte de 0,895, indicando que a mayores ingresos tienden a registrarse mayores gastos.

En EdadPromedioHogar, la media es 40,19 años y la mediana 38. Sin embargo, hay valores extremos de -5 y 120 años. El valor negativo no es posible y el máximo resulta altamente inusual para una edad promedio, por lo que pueden existir errores de carga o valores atípicos.

2. Verificación de Máximos y Mínimos (Feature Statistics):

Identifique los valores máximos y mínimos para IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Estos valores son realistas? Discuta cualquier valor que parezca inusual o fuera de lo esperado.

Los valores mínimos y máximos se analizaron mediante Column Statistics y posteriormente se contrastaron con las distribuciones gráficas. El IngresoMensual varía entre \$40.607,4 y \$148.558, mientras que GastoMensual se encuentra entre \$20.623,9 y \$127.691. Aunque presentan rangos amplios, estos valores pueden considerarse plausibles dentro de una muestra heterogénea de hogares.

En cambio, EdadPromedioHogar presenta un mínimo de -5 años y un máximo de 120 años (ya mencionado anteriormente, tanto el mínimo como el máximo resultan altamente atípicos)

La comparación entre estadísticas y gráficos permite detectar que el problema no está solamente en la magnitud de la dispersión, sino también en la calidad de algunos registros. Estos datos deberían revisarse antes de alimentar modelos predictivos o análisis más complejos.

3. Relación entre Variables (Scatter Plot):

Explore la relación entre el EdadPromedioHogar y otras variables numéricas como IngresoMensual y GastoMensual. ¿Hay alguna tendencia visible que indique cómo la edad promedio del hogar afecta los ingresos y gastos?

Para analizar la relación entre EdadPromedioHogar y las variables económicas se utilizaron gráficos de dispersión y posteriormente se contrastaron los patrones visuales mediante el widget Correlations.

En el Scatter Plot de EdadPromedioHogar e IngresoMensual no se observa una tendencia ascendente ni descendente clara. Los hogares con edades promedio similares presentan niveles de ingreso muy diferentes. Esto coincide con una correlación de Pearson de **-0,010**, prácticamente nula, indicando que en esta muestra no existe una asociación lineal relevante entre ambas variables.

El comportamiento es similar para GastoMensual. En el Scatter Plot se observa una gran dispersión: para edades comprendidas aproximadamente entre 20 y 60 años existen tanto hogares con gastos bajos como hogares con gastos elevados, sin conformarse un patrón lineal evidente. La correlación entre EdadPromedioHogar y GastoMensual es de **-0,051**, nuevamente muy próxima a cero.

La incorporación de ZonaVivienda mediante colores y TipoVivienda mediante diferentes formas permite analizar simultáneamente otras dimensiones del dataset. Se observa que los hogares urbanos tienden a concentrarse en edades promedio menores y los rurales alcanzan edades mayores, aunque dentro de cada grupo los niveles de gasto continúan siendo muy variables.

Por lo tanto, **la edad promedio del hogar no parece ser por sí sola una variable útil para explicar o predecir los ingresos o gastos mensuales de esta muestra**. En cambio, otras variables, como la zona de residencia, parecen presentar patrones demográficos más definidos.

Finalmente, el Scatter Plot vuelve a evidenciar observaciones extremas en EdadPromedioHogar, incluyendo valores negativos y superiores a 100 años, que deberían revisarse antes de realizar análisis predictivos.

4. Análisis de Outliers (Box Plot):

Utilizando técnicas gráficas, identificar datos atípicos en las variables numéricas. Describa por qué estos puntos podrían considerarse atípicos y qué factores podrían explicar estos valores.

Para identificar datos atípicos se utilizaron Box Plot, Distributions y Violin Plot, complementando el análisis gráfico con el rango intercuartílico.

En **IngresoMensual**, el primer cuartil es \$60.946,1, la mediana \$91.055,7 y el tercer cuartil 120.388. Utilizando el criterio de 1,5 veces el rango intercuartílico, los valores mínimo y máximo observados (\$40.607,4 y \$148.558) permanecen dentro de los límites esperados. Por lo tanto, no se detectan outliers claros en esta variable. La amplitud observada representa más bien heterogeneidad económica entre los hogares.

En **GastoMensual**, los cuartiles son \$41.105,8 y \$80.709, con una mediana de \$62.352,3. El máximo de \$127.691 también se encuentra dentro del rango esperado según el criterio intercuartílico, por lo que tampoco se identifican valores atípicos estadísticos importantes.

En cambio, **EdadPromedioHogar** presenta un comportamiento diferente. El primer cuartil es 31,15 años, la mediana 38 y el tercer cuartil 49,55. Aplicando el criterio de $1,5 \times \text{IQR}$, los valores por debajo de aproximadamente 3,55 años o por encima de 77,15 años pueden considerarse atípicos.

En esta variable aparecen registros de -5 y valores superiores a 100 años, incluyendo un máximo de 120. El valor -5 constituye claramente un error de calidad de datos, mientras que las edades extremadamente altas podrían corresponder a errores de carga o a casos muy excepcionales que deberían verificarse.

Este análisis demuestra que **un valor extremo no necesariamente es un outlier**. Ingreso y gasto presentan valores elevados pero compatibles con la distribución general, mientras que EdadPromedioHogar sí contiene observaciones que se apartan claramente del comportamiento del resto de la muestra.

5. Comparación entre Grupos (Box Plot): Analice cómo varía la EdadPromedioHogar entre diferentes tipos de vivienda (Casa, Departamento) y zonas de vivienda (Urbana, Suburbana, Rural). ¿Existen diferencias significativas que puedan sugerir patrones demográficos?

Para verificar que los valores anómalos no estuvieran condicionando los resultados, se realizó un proceso de limpieza mediante el widget Select Rows, excluyendo los registros con **EdadPromedioHogar < 0**. De esta manera se eliminó un dato imposible correspondiente a una edad promedio de -5 años y la muestra pasó de 100 a 99 observaciones.

Antes de la limpieza, la comparación por ZonaVivienda presentaba un ANOVA de 9,612 con $p < 0,001$. Luego de eliminar el registro inválido y repetir el análisis mediante Box Plot, el ANOVA aumentó a **10,241**, manteniéndose **$p < 0,001$** . Por lo tanto, las diferencias entre zonas continúan siendo estadísticamente significativas y no dependen del dato erróneo detectado.

Además, la limpieza permitió observar que el registro inválido pertenecía al grupo suburbano. Su edad promedio aumentó de aproximadamente 38,91 a **40,24 años**, mientras que los valores de las zonas urbana y rural permanecieron prácticamente sin cambios.

Luego de la limpieza, las edades medias fueron **32,89 años para la zona urbana, 40,24 para la suburbana y 49,32 para la rural**, mostrando un patrón creciente desde las zonas urbanas hacia las rurales.

Este procedimiento demuestra la importancia de realizar controles de calidad y repetir los análisis después de la limpieza de datos. En este caso, la eliminación del valor imposible no modifica la conclusión original, sino que confirma el patrón observado.

6. Correlaciones (Correlations):
Investigue la correlación entre las variables numéricas. ¿Qué relaciones se pueden identificar como relevantes y cómo se interpretan?

Mediante el widget Correlations se analizaron las asociaciones lineales entre las variables numéricas. La relación más relevante aparece entre IngresoMensual y GastoMensual, con un coeficiente de Pearson de

0,895. Esto representa una correlación positiva muy fuerte: los hogares con mayores ingresos tienden también a presentar mayores niveles de gasto.

En cambio, las relaciones de EdadPromedioHogar con IngresoMensual (-0,010) y GastoMensual (-0,051) son prácticamente nulas. Lo mismo ocurre entre NumPersonas e IngresoMensual (-0,014) y entre NumPersonas y GastoMensual (0,059). Por lo tanto, en esta muestra no se observan asociaciones lineales importantes entre estas variables.

También aparecen correlaciones con HogarID, pero estas no deberían interpretarse económicamente porque HogarID es solamente un identificador de cada registro y no una característica real del hogar. En un proceso de preparación de datos sería recomendable convertirlo en meta variable o excluirlo de los análisis predictivos.

En conclusión, el patrón más fuerte encontrado en el dataset es la relación entre ingresos y gastos, mientras que el resto de las variables presenta correlaciones lineales débiles o prácticamente inexistentes.